

Fundamentos de IA y Machine Learning - Tarea lección 4

Kevin Martínez García

13 de septiembre de 2022

Índice

1. <i>Deep Learning</i> : concepto y fundamento	2
2. Redes neuronales multicapa	2
3. Redes neuronales convolucionales	2
4. Redes neuronales recurrentes	3
5. Aplicaciones	3

1. *Deep Learning*: concepto y fundamento

El *Deep Learning* hace referencia a una rama del *Machine Learning* que se basa en el uso de redes neuronales artificiales. En concreto, al usar el término *Deep Learning* hacemos referencia a arquitecturas de aprendizaje que utilizan varias capas en su funcionamiento, es decir, disponemos de **más de una capa** entre las de salida y entrada [1]. A este tipo de aprendizaje pertenecen algunas arquitecturas como las redes neuronales profundas, las redes neuronales recurrentes y las redes neuronales convolucionales, que introduciremos en los siguientes apartados.

2. Redes neuronales multicapa

En términos formales, podríamos definir una red neuronal multicapa mediante la siguiente expresión:

$$y = f_{NN}(\mathbf{x}) \quad (1)$$

Siendo \mathbf{x} una entrada en forma de vector y f_{NN} una función compuesta. Por ejemplo, para una red neuronal con 3 capas que devuelve una magnitud escalar, la función f_{NN} tendría el siguiente aspecto:

$$y = f_{NN}(\mathbf{x}) = f_3(f_2(f_1(\mathbf{x}))) \quad (2)$$

Las funciones f_1 y f_2 suelen ser funciones vectoriales que dependen de ciertos parámetros a optimizar mediante *descenso por gradiente* [2]. En términos prácticos, las redes neuronales multicapa tienen la capacidad de modelar relaciones complejas (no lineales) entre las características de un conjunto de instancias, y resultan especialmente útiles algunas áreas de la ciencia como la visión por computador, el reconocimiento del discurso o el procesamiento del lenguaje natural.

Esta capacidad de las redes neuronales suele venir con dos claras desventajas. Por una parte, el tiempo de entrenamiento de las redes neuronales puede ser significativamente mayor que el de otros modelos más sencillos y, a mayor número de capas, mayor número de parámetros a almacenar, lo que puede suponer problemas de almacenamiento en redes neuronales extremadamente complejas.

3. Redes neuronales convolucionales

Como se ha explicado en la sección anterior, uno de los inconvenientes de las redes neuronales multicapa, es la cantidad de parámetros que se pueden llegar a necesitar. Esto conlleva no solo problemas de almacenamiento, sino también problemas al aplicar algoritmos de optimización de los mismos. Las *redes neuronales convolucionales* buscan por tanto reducir significativamente el número de parámetros de las redes, sin perder calidad en el modelo obtenido. Además su principal aplicación es el procesamiento de imágenes.

Este tipo de redes neuronales dividen sus entradas en segmentos o *patches* para cierto valor de p . Es decir, para un valor $p = 128$, las imágenes de entrada se dividen en *patches* de 128×128 píxeles (que se representarían mediante una matriz \mathbf{P}). Para procesar estos segmentos, el modelo aprende unas matrices de parámetros \mathbf{F} que “procesan” cada uno de los *patches*. En concreto, se calcula la *convolución* de \mathbf{F} con \mathbf{P} para obtener cierto valor. Cuanto más alto es dicho valor, mayor similitud entre \mathbf{F} y \mathbf{P} .

La *convolución* es un tipo de operación definida únicamente para matrices con las mismas dimensiones y, en el caso de las redes neuronales convolucionales, suele corresponderse con el *producto interno de Frobenius* [3]. Este tipo de producto, toma dos matrices y calcula su *producto interno* devolviendo un escalar que, como se ha indicado previamente, nos da una idea de la similitud entre las matrices \mathbf{P} y \mathbf{F} .

Este tipo de redes neuronales se han aplicado con gran éxito en el reconocimiento de imágenes, logrando una exactitud mayor al 99 % con algunos conjuntos de datos como el *MNIST* [4] así como en el reconocimiento facial, decrementando además el tiempo necesario de entrenamiento.

4. Redes neuronales recurrentes

Las redes neuronales recurrentes se suelen utilizar para etiquetar, clasificar o generar secuencias. En general, las secuencias se suelen representar como matrices dónde cada fila representa un vector de características y el orden de estas filas es importante (no se podría hacer un "barajado" aleatorio como es habitual con otros tipos de datos). Las predicciones de este modelo se realizan sobre toda la secuencia (en lugar de cada fila como es habitual) y la generación de secuencias se trata de generar una secuencia relevante o relacionada con la de entrada.

Una característica llamativa de las redes neuronales recurrentes es que contienen *bucles*. Es decir, cierta unidad o neurona u en una capa l recibe dos entradas; por una parte un vector de estados generado en la capa $l - 1$ y por otra, un vector de estados de su propia capa l generado un un paso anterior [2]. Esta particularidad permite a este tipo de redes les permite tener un comportamiento dinámico con el tiempo. Este comportamiento hace que este tipo de redes neuronales se apliquen a problemas de reconocimiento del discurso y la escritura (además de ser robustas a inputs de longitud variable) [5].

5. Aplicaciones

Como hemos visto en las secciones anteriores, las redes neuronales tienen un gran número de aplicaciones debido a su alto poder predictivo. Algunas áreas de la ciencia como reconocimiento del discurso, reconocimiento de la imagen, procesamiento del lenguaje, sistemas de recomendación, bioinformática y procesamiento de imágenes médicas suelen hacer un uso intensivo de este tipo de redes.

Es tanta la capacidad predictiva que numerosos sectores de la industria hacen uso de las mismas. La creación de asistentes virtuales, chatbots, sistemas recomendadores de música, películas o productos todos se sirven este tipo de tecnología. El reconocimiento de tejidos cancerosos en imágenes obtenidas por radiografía es otra de las prometedoras aplicaciones que, posiblemente, lograrán reducir la mortalidad de la enfermedad mediante la detección temprana de los tejidos.

En definitiva, las redes neuronales y el *deep learning* poseen la capacidad de automatizar e incluso mejorar la ejecución de muchas tareas que podrían suponer un esfuerzo incalculable para un ser humano.

Referencias

- [1] Wikipedia. (2020). Deep learning. [online] Available at: https://en.wikipedia.org/wiki/Deep_learning#Deep_neural_networks.

- [2] Andriy Burkov (2019). The hundred-page machine learning book. Quebec, Canada] Andriy Burkov.
- [3] Wikipedia. (2022). Frobenius inner product. [online] Available at: https://en.wikipedia.org/wiki/Frobenius_inner_product [Accessed 13 Sep. 2022].
- [4] Lecun.com. (2009). MNIST handwritten digit database, Yann LeCun, Corinna Cortes and Chris Burges. [online] Available at: <http://yann.lecun.com/exdb/mnist/>.
- [5] Wikipedia Contributors (2018). Recurrent neural network. [online] Wikipedia. Available at: https://en.wikipedia.org/wiki/Recurrent_neural_network.